

Propuesta de Arquitectura de Datos

Proyecto: Café Norte (Solución ELT con AWS)

1. Resumen Ejecutivo y Visión de Negocio

Las pequeñas y medianas empresas (PyMES) sin importar sector enfrentan retos cotidianos que son críticos: pérdida por márgenes negativos no detectados, desabastos en sucursales, y desconexión entre sus diferentes canales de venta (físicos y digitales).

La presente propuesta implementa una **arquitectura de datos en AWS bajo un enfoque ELT (Extract, Load, Transform)**. Está diseñada específicamente para flujos de datos moderados, pero garantizando una solución escalable, de bajo costo operativo y con un alto retorno de inversión analítica.

2. Arquitectura del Flujo de Datos (ELT)

La solución se compone de cuatro etapas clave optimizadas :

1. **Ingesta y Desarrollo Local:** Procesamiento en Python 3.12 (VS Code) y Pandas para la limpieza, manejo de JSONs anidados y conexión segura vía s3fs.
2. **Almacenamiento en la Nube (Amazon S3):** Separación en dos capas clave:
 - s3://amz-coffenorth-data/crudo/ (Recepción de archivos heterogéneos: CSV, JSON, Parquet).
 - s3://amz-coffenorth-data/limpio/ (Persistencia masiva en formato columnar optimizado Apache Parquet).
3. **Procesamiento Cloud (AWS Glue):** Automatización del pipeline de transformación ejecutándose de forma serverless.
4. **Motor Analítico (AWS Athena):** Ejecución de consultas SQL de negocio mediante CTAS para la toma de decisiones gerenciales.

En caso de que se presente un incremento en los datos se puede realizar la migración hacia PySpark para la división computacional sobre AWS EMR así como agregando Eventos con Lambda para que se programen eventos ELT en el horario indicado así como realizando la entrega de manera automatizada sobre algún correo, portal o número telefónico.

3. Conclusión y Escalabilidad

Esta propuesta demuestra que no se necesita una infraestructura compleja ni costosa para digitalizar una empresa. Con una inversión ligera en servicios administrados de AWS y código limpio en Python, se asegura el control de datos de manera segura, visibilidad, los archivos limpios en caso de que se requiera realizar un análisis más profundo así como un plan en caso de que se desee escalar para el crecimiento comercial.

Diagrama de flujo de datos

1 PC Local Carga manual de archivos origen o en caso de que se requiera programar evento	2 Amazon S3 (Crudo) s3://amz-coffenorth-data/crudo/ Recepción de archivos heterogéneos.	3 AWS Glue (Job Cloud) Disparo manual o por lotes para proceso ELT en infraestructura cloud.
4 Proceso ETL/ELT (Pandas) Limpieza, normalización y aplanamiento de JSONs con Python/Pandas	5 Amazon S3 (Limpio) s3://amz-coffenorth-data/limpio/ Persistencia de datos en formato Parquet.	6 Amazon Athena Motor SQL para análisis de negocio indicados sobre los datos limpios.
7 Consultas CTAS s3://amz-coffenorth-data/resultados/QuerysPrincipales Almacenamiento de tablas con resultados analíticos	8 Análisis y Reportes de Negocio Entrega de archivos Parquet limpios y preguntas de negocio	